



Proiect Instrumente și Tehnici de Bază în Informatică

Dănilă Tudor-Mihail
Neica Mario-Alexandru



Tema proiectului

HTML Pretty Printer

Scrieți un program script(shell) care primește ca input un fișier HTML și îl formatează a.î. să reflecte vizual structura ierarhică și nivelul de îmbricare al resurselor folosite prin indentarea corespunzătoare a tag-urilor și strigurilor.

Soluția adoptată

1. Prelucrarea inițială a fișierului

- HTML-ul original poate fi pe o singură linie sau cu mai multe tag-uri lipite pe aceeași linie. Acest lucru îl face greu de citit așa că mai întâi se împarte fiecare linie în bucăți mai mici, astfel încât fiecare tag (`<html>`, `</body>`, etc.) sau text între tag-uri să fie pe o linie separată.
- Pentru această rezolvare se adaugă un caracter de newline (`\n`) înaintea fiecărui `<` și după fiecare `>`, urmând ca apoi să se elimine liniile goale rezultate în urma acestei operații.

Soluția adoptată

2. Indentarea fișierului pentru a reflecta structura ierarhică

- HTML-ul are o structură bazată pe tag-uri care se pot cuibări unul în altul.
- Pentru a reprezenta această structură, se folosește o variabilă `nr_tab`, care ține evidența nivelului curent de imbricare. Mai exact: când se întâlnește un tag de deschidere (ex: `<div>`), se duce la un nivel mai adânc de imbricare (se incrementează `nr_tab`), iar când se întâlnește un tag de închidere (ex: `</div>`), se întoarce la nivelul anterior (se decrementează `nr_tab`). Când se întâlnește un tag cu auto-închidere, nivelul rămâne același.
- La fiecare linie, se aplică un număr de spații care corespunde nivelului de imbricare curent.

Soluția adoptată

3. Generarea unui fișier de ieșire

- Se salvează rezultatul într-un nou fișier cu un nume generat automat, astfel încât să nu fie suprascris fișierul original.
- Numele fișierului de ieșire adaugă sufixul `_formatted` la numele fișierului original.

Dificultăți confruntate

1. Prelucrarea inițială a fișierului

- O primă problemă întâlnită constă chiar în primul pas al rezolvării. Cum nu toate fișierele de intrare au aceeași structură(de exemplu: numărul de spații poate fi diferit, codul poate fi scris pe o linie/două/etc.), codul trebuie inițial să aducă orice fișier HTML la aceeași structură.
- Ca rezolvare a acestei probleme, creăm un fișier intermediar în care spargem codul în mai multe linii(fiecare tag și linie-text pe o linie separată).

Dificultăți confruntate

2. Abordarea tag-urilor cu auto-închidere

- O a doua problemă întâlnită constă în modul în care prelucrăm tag-urile cu auto-închidere. Cum în fișierele HTML tag-urile cu auto-închidere sunt scrise pe aceeași linie, nu putem folosi aceeași rezolvare ca pentru tag-urile obișnuite, cum ar fi `<div>`, `</div>`.
- Ca rezolvare a acestei probleme, nu se actualizează numărul de tab-uri.
- Verificăm manual tag-urile `<area>`, `<base>`, `<br>`, `<col>`, `<embed>`, `<hr>`, `<img>`, `<input>`, `<link>`, `<meta>`, `<source>`, `<track>`, `<wbr>`.

Rezultate experimentale(input)

Fișierul initial

```
<html><head><meta charset="UTF-8"/><title>Page 4</title></head><body><header><h1>Welcome to My Website</h1><nav><ul><li><a href="#">Home</a></li><li><a href="#">About</a></li><li><a href="#">Services</a></li><li><a href="#">Contact</a></li></ul></nav></header><section><h2>Introduction</h2><p>This is the introduction section.</p><p>Additional details about the page.</p></section><section><h2>Details</h2><p>More content in this section.</p><p>Even more content to expand this section.</p><div><h3>Subsection 1</h3><p>This is a paragraph in subsection 1.</p></div><div><h3>Subsection 2</h3><p>This is a paragraph in subsection 2 with even more content.</p></div></section><footer><p>Footer content goes here.</p></footer></body></html>
```


Rezultate experimentale(output)

```
input_4.html  input_4_formatted.html X  input_4.html  input_4_formatted.html X  input_4.html  input_4_formatted.html X

D: > Facultate > Semestrul I > ITBI > Proiect > input-output > input_4.html
1  <html>
2  <head>
3  <meta charset="UTF-8"/>
4  <title>
5  |   Page 4
6  </title>
7  </head>
8  <body>
9  <header>
10 |   <h1>
11 |   |   Welcome to My Website
12 |   </h1>
13 |   <nav>
14 |   |   <ul>
15 |   |   |   <li>
16 |   |   |   |   <a href="#">
17 |   |   |   |   |   Home
18 |   |   |   |   </a>
19 |   |   |   </li>
20 |   |   |   <li>
21 |   |   |   |   <a href="#">
22 |   |   |   |   |   About
23 |   |   |   |   </a>
24 |   |   |   </li>
25 |   |   |   <li>
26 |   |   |   |   <a href="#">
27 |   |   |   |   |   Services
28 |   |   |   |   </a>
29 |   |   |   </li>
30 |   |   |   <li>
31 |   |   |   |   <a href="#">
32 |   |   |   |   |   Contact
33 |   |   |   |   </a>
34 |   |   |   </li>
35 |   |   </ul>
36 |   </nav>
37 </header>

D: > Facultate > Semestrul I > ITBI > Proiect > input-output > input_4_formatted.html
1  <html>
8  <body>
9  <header>
37 </header>
38 <section>
39 <h2>
40 |   Introduction
41 </h2>
42 <p>
43 |   This is the introduction section.
44 </p>
45 <p>
46 |   Additional details about the page.
47 </p>
48 </section>
49 <section>
50 <h2>
51 |   Details
52 </h2>
53 <p>
54 |   More content in this section.
55 </p>
56 <p>
57 |   Even more content to expand this section.
58 </p>
59 <div>
60 |   <h3>
61 |   |   Subsection 1
62 |   </h3>
63 |   <p>
64 |   |   This is a paragraph in subsection 1.
65 |   </p>
66 |   </div>
67 <div>
68 |   <h3>
69 |   |   Subsection 2
70 |   </h3>
71 |   <p>
72 |   |   This is a paragraph in subsection 2 with even more content.
73 |   </p>
74 |   </div>
75 </section>
76 <footer>
77 <p>
78 |   Footer content goes here.
79 </p>
80 </footer>
81 </body>
82 </html>

D: > Facultate > Semestrul I > ITBI > Proiect > input-output > input_4.html
1  <html>
8  <body>
49 <section>
50 <h2>
52 </h2>
53 <p>
54 |   More content in this section.
55 </p>
56 <p>
57 |   Even more content to expand this section.
58 </p>
59 <div>
60 |   <h3>
61 |   |   Subsection 1
62 |   </h3>
63 |   <p>
64 |   |   This is a paragraph in subsection 1.
65 |   </p>
66 |   </div>
67 <div>
68 |   <h3>
69 |   |   Subsection 2
70 |   </h3>
71 |   <p>
72 |   |   This is a paragraph in subsection 2 with even more content.
73 |   </p>
74 |   </div>
75 </section>
76 <footer>
77 <p>
78 |   Footer content goes here.
79 </p>
80 </footer>
81 </body>
82 </html>
83
```

Vă mulțumim
pentru atenția
acordată!